

期中報告

基於圖像語意分割優化道路裂痕檢測

國立高雄科技大學

海事資訊科技系

組長：000

組員：000

組員：000

組員：000

組員：000

指導老師：000 老師

(一)摘要

道路毀損對用路安全的威脅日益嚴重，如何以資通訊科技提升道路品質維護的效率，是近來智慧交通研究領域的重要研究議題。其中，路面檢測技術是用於檢測道路是否產生裂痕而危及用路安全。然而，現行檢測路面裂痕方法受到準確度的限制，如何提升路面裂痕效率的高準確度檢測技術仍待發展。檢測準確性主要受限於道路裂痕的影像不均勻、影像複雜度高，以及影像雜訊和裂痕紋理相近等問題。本計畫研擬發展一種名為 HUNET(Hybrid U-Net)的混合神經網路語義分割方法，以實現高性能的道路裂痕檢測技術。本計畫預期貢獻包含：(1)結合經典 U-Net 方法重新定義構成裂紋的標記，並以強度不均勻性更好地表示裂紋；(2)運用遷移學習建構高性能的道路裂痕語意分割網路，識別複雜的裂痕紋路；(3)運用綜合性損失函數訓練模型加快收斂速度，並以及準確性及交集聯集性能指標評估各方法性能。本計畫預期 HUNET 將優於傳統的 U-Net 和 SegNet 語義分割方法的檢測準確度。

(二)研究動機與研究問題

研究動機：

路面損毀造成的裂痕，是一種道路已受到損壞的警訊，顯示道路狀況已威脅交通安全，各國政府為實現交通建設連結城市間的運輸渠道，投入大量成本強化交通建設[1]。然而，交通建設完成後需有完整的道路維護計畫支援，以維持道路品質及用路安全。道路裂痕檢測是道路維護系統的重要部分之一，隨著交通建設的擴展，道路裂痕檢測受到高度重視。傳統的人工道路裂痕檢測方法耗時費力、具潛在風險、勞動密集且高度依賴主觀因素[2]。因此，傳統方法逐漸被自動裂痕檢測所取代，自動裂痕檢測近年已陸續投入開發用於智慧運輸系統中，眾多交通產業期盼發展快速可靠的裂痕分析，認為高性能的自動裂痕檢測系統可以量化路面品質，並有助於對道路系統的維護進行優先順序安排和計畫，從而使道路維護狀況良好，使用壽命更長[6]。

研究問題：

現有的道路裂痕檢測技術，大多是基於人工或傳統的影像處理方法，檢測道路裂痕的成本高昂，且準確度仍有待提升，難以推展全面及持續的道路品質檢測，危及用路人安全及民眾生命健康。發展高準確度的道路裂痕檢測技術以提升交通安全是極為迫切需求。因此，本計畫所要探討【研究問題】包含：

- (1) 如何運用深度學習進行道路裂痕影像自動化辨識
- (2) 如何運用深度學習改善道路裂痕紋路相近難以辨識問題

- (3) 本計畫所提出之語意分割方法與經典方法的性能差異
- (4) 現有深度學習於道路裂痕檢測的現況與進展
- (5) 現有道路裂痕影像檢測技術的改善方向

(三)文獻探討與回顧

道路裂痕檢測

隨著影像處理技術的發展，過去道路裂痕檢測和辨識一直受到廣泛討論與重視[3]。在道路裂痕檢測研究中[12, 13]，研究人員常使用基於閾值的方法查找裂痕區域，這類方法須假設實際裂痕紋路的亮度始終比周圍環境影像更暗，僅考慮亮度特性，並且對雜訊非常敏感，且僅在單個像素上執行，缺乏整體資料觀點也使這些方法的結果未能預期。此外，這些方法對於處理強度不均勻或拓撲結構複雜的裂紋也無法達到有效的辨識能力。可能的原因在於使用的特徵僅粗略地捕獲了影像的灰度資訊，導致裂痕的獨特特徵無法正確呈現和利用。此外，現有方法會忽略局部結構化資訊。實際上，局部影像中的裂痕高度相關，並且通常包含常見的圖案，例如垂直、水平及對角線等。因此，能夠考量像素間關係的解決方法：結構化學習，受到裂痕檢測領域的重視，過去研究如[24]中，研究人員將結構化學習應用於語義影像標記，其中影像的標記是依賴於彼此的關係。

近年深度卷積神經網路(Depth Convolution Neural Network, DCNN)在影像辨識研究領域展現更勝於人工辨識的性能，受到了高度重視[8]，如目標檢測[9]，影像分割[10, 11]等研究領域。對於線條檢測，提出基於 DCNN 的方法執行諸如邊緣檢測[12, 13]、輪廓檢測[14, 15]和邊界分割[16, 17]等。這些深層架構通過階層式卷積感知輸入，基於低層級的基礎特徵上構建高階特徵。深度學習的研究結果指出，運用深度學習於邊緣檢測時，卷積特徵在卷積池管道中會變得越來越粗略，高階的詳細特徵和低階的抽象特徵可進行融合以提高邊緣檢測的性能[13, 18, 19]。當使用深度學習進行影像分割時，例如 SegNet 的特點，是運用自動編碼器網路(Autoencoder, AE)中的卷積特徵提高語義影像分割的性能，並且利用池化層索引(Pool Index)提升邊界準確性[20]。

SegNet

SegNet[24]架構的組成要素包含：(1)非線性處理編碼器層(encoder)，(2)相對應的一組解碼器(decoder)，(3)接續一個像素分類器。通常每個編碼器由一個或多個卷積層組成，具有批量歸一化(Batched Normalization, BN)和整流線性單元函數(Rectified Linear Unit, ReLU)，然後是非重疊的最大池化層(Pool layer)和上採樣層(Up sampling Layer)。資料輸入經池化層過程產生的稀疏編碼，將在解碼器層(Encoder Layer)中使用編碼序列中的池化層索引(Pool Index)進行上採樣(Upsampling)，如圖 1。SegNet 的優點是運用解碼器中池化層索引執行低解析度

特徵圖的上採樣，保留了分割影像中的高頻細節和減少解碼器中需要訓練參數量。整個架構可以使用隨機梯度下降法進行端到端訓練(End to End)，即使沒有基於條件隨機場(Conditional Random Field, CRF)的後處理，SegNet 的預測能力仍相當穩定[24]。




圖 2 SegNet 架構圖。藍色方塊為捲積層及批量歸一化層及 ReLU，綠色為上採樣，黃色為池化層，粉紅色則為 SoftMax 層

U-Net

用於分割的 U-Net 如圖 2 所示。U-Net 網路的前半部分執行特徵選擇，後半部分執行上採樣。這種網路結構也稱為自動編碼器神經網路(Autoencoder, AE)，AE 分為編碼器及解碼器兩個部分。U-Net 的網路架構仿效 AE 中的前半部分編碼器，它重複卷積層和最大池化層。路徑上每經過兩個 3×3 卷積層後，再增加一個 2×2 的最大池化層和卷積層後，使用整流線性單元(ReLU)激勵函數(Activate Function)對原始影像進行下採樣(Downsampling)，每一次下採樣都會增加一個新的通道數，解碼路徑後半段的每一個層級步驟都需要對特徵圖連續進行轉置卷積和卷積運算。在解碼路徑的上採樣階段，在每層轉置卷積之後，增加一個 ReLU 函數和兩個 3×3 卷積層。每一次上採樣都會增加一個相應編碼路徑的特徵圖，從而使特徵通道數減少一半。在 U-Net 中，低階特徵和高階特徵相互結合；對低階特徵進行多次下採樣後，低階特徵可以提供分割目標在整個影像中的上下文語義資訊，反映目標的特徵與環境的關係，該功能確定物件類別，在編碼器和解碼器之間採用跳躍連接。而應用於高階資訊的跳躍連接操作，是將編碼器的資訊直接傳遞給在相同頻寬下解碼的高階資訊，提供語意分割更詳細的特徵。當低、高階資訊相結合時，直接監督語義特徵和損失反傳播，恢復後的特徵圖融合了更多的低階資訊特徵，以及不同尺度的特徵。與其他網路不同的是，U-Net 採用特徵融合的方式進行合併，在通道維度上將特徵合併在一起，形成更厚實的特徵。陸續有研究提出了改進了 U-Net 的版本 UNet++[25]，與原來的 U-Net 網路相比，強化了 U-Net 結構中的跳轉連接部分，UNet++將 U-Net 的第 1 至 4 層連接。




圖 2 U-Net 架構圖

以深度學習為基礎的方法開創了語意分割的一系列應用，而 SegNet 和 U-Net 則是其中的經典方法。使用 U-Net 用於裂痕影像的分割主要有 2 點優勢：(1) 裂痕影像的邊界模糊及梯度複雜，使用 U-Net 有利於學習準確的語義分割；(2) 裂痕結構不固定，語義複雜，使用 U-Net 能夠有效擷取裂痕特徵。因此，本計畫將以 U-Net 為基礎進行改良優化。

(四)研究方法與步驟

本計畫設計一種基於 U-Net 語義分割的方法 HUNET(Hybrid U-Net)，作為道路裂痕檢測方法，圖 3 顯示該方法的整體流程。HUNET 方法由 3 個階段組成，包括：(1) 資料增強(Data Augmentation)，(2) 裂痕影像提取語義分段，以及(3) 結果整合及後處理。在第一階段，本計畫設計了一種資料融合方法，能充分利用道路影像和裂痕影像的資訊。為避免訓練樣本不足，導致模型過度適配或是適配度不足的問題，本計畫研擬對資料集進行資料增強處理，以提升模型的一般化能力。在第二階段，本計畫訓練及評估 HUNET 語義分割模型，該模型是基於已廣泛用於許多遙感影像分割研究的 U-Net 為基礎，具備可靠度及準確度。第三階段，本計畫應用影像整合和後處理策略，完善道路裂痕影像提取。以下各節介紹每階段的詳細資訊。




圖 3 HUNET 道路裂痕影像分割流程圖，第一階段資料增強為(a-c)，第二階段裂痕影像提取語義分段為(d)，第三階段影像整合和後處理為(e-g)。

資料增強

資料增強是避免訓練樣本不足導致過度擬合的有效策略，可提高深度學習模型的泛化能力。語義分割模型具備大量的超參數，因而需要大量的樣本訓練模型。然而，資料集中常有某類類別的訓練樣本數相對較少，因此本計畫採用資料增強策略解決此問題。資料增強策略包含：縮放，切片和旋轉，以增加訓練樣本和語義分割模型的數量和多樣性。本計畫將資料集進一步預處理為 2 種格式的輸入影像，以訓練語義分割模型。而增強策略實施方式是先將每個尺寸為 650×650 像素的影像重新縮放為 256×256 像素影像，再將每個 650×650 像素的影像切成 256×256 像素的 3×3 子影像。另外，也透過 2 種 90 度旋轉影像增加訓練影像數量。




圖 4 HUNET 神經網路結構

道路裂痕影像語義分割模型

1. HUNET 神經網路架構

圖 4 顯示了用於道路提取任務的語義分割模型的神經網路結構，包括每層的名稱和大小。HUNET 由六部分組成：(1)多個 3×3 卷積核進行特徵提取的卷積層；(2)在訓練階段加速收斂的批次正規化層(Batched-Normalization)；(3)用於特徵圖的非線性變換的啟動函數層 ReLU；(4)用於特徵圖的下採樣的最大池化層；(5)上採樣層，用於恢復被最大池化層下採樣的特徵圖的大小；(6)合併層，用於將較深層的上採樣特徵圖與來自淺層的相應特徵圖合併。對於語義分割模型的最後批次正規化層，本計畫採用 Sigmoid 函數為激勵函數層，獲得逐個像素及機率圖。最後，本計畫使用設定的臨界值(在常見情況下為 0.5)對機率圖進行二元化處理，以獲取預測的裂痕影像提取結果(語義分割網路的輸出)，並對輸出影像進行向量化處理，以獲取預測的裂痕影像範圍。

2. 模型訓練與評估

為了訓練語義分割模型，我們選擇 Adam 作為優化方法，選擇二元交叉熵作為損失函數。由於圖形處理單元(Graphic Processing Unit, GPU)記憶體受限，在本研究中，訓練階段的批次處理大小設置為 8，學習率設置為 0.001，最大 epoch 值設

置為 1000，採用早期停止訓練策略(Early stopping)，監控損失函數是否持續收斂，以避免潛在的過度適配或適配不足的問題。設定容忍 epoch 值為 200，若每次訓練歷經 200 次 epoch 仍未收斂，便會停止模型訓練。

結果整合及後處理

本計畫為每個驗證樣本獲得了 4 組機率圖(每組的大小為 256×256 像素)。機率圖中每像素值表示該像素屬於裂痕區域的預測機率。對於每個驗證樣本而言，共獲得 4 組機率圖，包含(1)具有縮放比例的道路影像，(2)具有切片策略的道路影像，(3)具有縮放比例的道路+裂痕影像及(4)道路+裂痕影像切片。對於第一和第三組，本計畫將單一機率圖重新縮放為原始樣本大小。對於第二組和第四組，本計畫將多個機率圖組合為與完整影像相對應的單個影像。因此，為每個驗證樣本獲得了 4 個機率圖(圖的大小為 650×650 像素)。

本計畫提出一種二階段集成策略，將每個模型獲得的結果集成到最終的道路裂痕提取結果。在第一階段，對道路影像資料集以及裂痕遮罩影像資料集的機率影像素值平均為 1 個集成機率圖。在第二階段，則是將 2 個集成機率圖進一步平均化為最終的裂痕遮罩機率圖。獲得集成機率圖後，接續應用 2 種後處理策略優化最終預測結果。在第一種策略中，將不同資料集的裂痕機率臨界值(表示像素屬於裂痕區域或非裂痕區域)從 0.45 調整為 0.55。將優化的機率臨界值用於將機率圖向量化為二元裂痕影像結果。在第二種策略中，為了濾除裂痕影像結果中的潛在雜訊，我們將每個裂痕的多邊形大小臨界值(指示裂痕多邊形的最小可能大小)從 90 像素調整為 240 像素。驗證資料集的機率和多邊形大小的優化臨界值，同樣應用於每個裂痕測試資料集。

Crack 500 資料集

Crack 500 資料集源於領域專家標注的國際資料集，常用於提高路面裂痕診斷的自動分割能力評估[30]。Crack 500 資料集共有 5188 張影像，包括路面裂痕影像和遮罩(Mask)影像，按照 8:2 的比例分為訓練集和測試集。

Crack 500 Dataset

DeepCrack 是路面裂痕研究中獲得的路面裂痕影像資料集，該資料集共有 400 張影像，包括路面裂痕影像和遮罩影像，按 8:2 的比例分為訓練集和測試集[31]。

模型性能評估方式

損失函數

本計畫採用損失函數啟發自骰子損失如公式(1)和二元交叉熵(Binary Cross Entropy, BCE) 如公式(2)，具體損失函數為公式(3)。當資料相對均衡時，交叉熵

有改善效果；但在資料極不均衡的情況下，經過多次訓練後，交叉熵損失會比骰子損失小很多。因此綜合骰子損失及交叉熵損失 2 者形成本計畫所使用之損失函數，如公式(3)，具有平衡 2 者優點之評估特色。

$$\text{Dice Loss} = 1 - \frac{1}{N} \sum_{i=1}^N \frac{2|p_i \cap y_i|}{|p_i| + |y_i|} \quad (1)$$

$$\text{BCE} = \frac{1}{N} \sum_{i=1}^N (y_i \log p_i + (1 - y_i) \log(1 - p_i)) \quad (2)$$

$$\text{Loss} = (1 - \alpha)\text{BCE} + \alpha\text{Dice} \times \text{Loss} \quad (3)$$

準確性

混淆矩陣將用於進行各方法的性能分析。混淆矩陣是由真陰性(TN：影像背景預測正確)、偽陰性(FN：影像背景預測錯誤)、偽陽性(FP：影像前景預測錯誤)和真陽性(TP：影像前景預測正確)組成。TP、FP、FN 和 TN 的混淆矩陣見表 1。

表 1 混淆矩陣

Predict result	Actual test	
	Positive	Negative
Positive	TP	FP
Negative	FN	TN

所有比較方法將使用準確性評估，公式如(4)。準確性範圍為 0 到 1 之間，越接近 1 表示準確性越高。除了計算二進位精度外，同時考慮閾值，默認為 0.5。每個預測值都會與閾值進行比較。大於閾值的值設置為 1，小於或等於閾值的值設置為 0。

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (4)$$

骰子係數

骰子係數是評估語意分割品質的常用指標。它主要用於計算兩個區間的骰子距離，以分割區間的相似度。骰子損失是為瞭解決前景影像比例過小時產生的問題，其範圍在 0~1 之間。當測量兩個樣本的重疊部分時，指標範圍在 0~1 之間（其中 1 代表完全重疊），公式如(5)：

$$\text{Dice} = \frac{2\text{TP}}{\text{FN} + 2\text{TP} + \text{FP}} \quad (5)$$

交集聯合

交集聯合(Intersection over Union, IoU)是用於輸出預測範圍的評估指標，為

了使 IoU 能夠用於檢測任何尺寸和形狀的物體，須要在訓練集影像中標記被檢測物體的範圍，亦即遮罩影像，並測量真值和預測值之間的相關性，公式如(6)。

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (6)$$

(五)預期結果

本計畫預期研究成果，將以本計畫所提出之 HUNET 和經典方法 U-NET 和 SegNet 以 2 個路面裂痕資料集進行效能驗證比較，預期 HUNET 能有更佳的精確度表現。計畫執行結束後，提供網路訓練方法和開放測試資料供驗證，供後續研究參考。具體而言，本計畫之預計結果如下：

1. 整理 3 模型比較結果：獲得 HUNET、U-Net 和 SegNet 等 3 種模型的性能比較結果，包含各方法的 2 種指標：準確性及骰子系数。
2. 模型一般化能力分析：探討本研究的自動檢測方法是否適用於其他檢測問題，執行上可能會面臨的問題與解決方案，並延伸討論如何增加本研究資料分析的一般化能力。
3. 管理及實務意涵：探討研究成果對於管理及實務上的兩種意涵；管理意涵探討道路損毀的主要來源類型，能有益於交通建設的規劃調整，以降低道路養護成本。實務意涵探討本計畫所提出之檢測方法，如何提升既有道路裂痕檢測精度，可供後續交通管理單位進行研究參考。
4. 訓練資料：為能提供後續研究發展不同領域的裂痕檢測技術，本計畫訓練神經網路的資料集，將於計畫完成後整理開放，供不同領域檢測研究延伸參考。

(六)參考文獻

1. H. D. Cheng; J. Wang; Y. G. Hu; C. Glazier; X. J. Shi, and X. W. Chen, Novel approach to pavement cracking detection based on neural network. *Transportation Research Record*, **2001**, 1764, 119-127.
2. P. Subirats; J. Dumoulin; V. Legeay, and D. Barba, "Automation of pavement surface crack detection using the continuous wavelet transform," in *2006 International Conference on Image Processing*, 2006; pp. 3037-3040.
3. M. Petrou; J. Kittler, and K. Y. Song, Automatic surface crack detection on textured materials. *Journal of Materials Processing Technology*, **1996**, 56, 158-167.
4. D. L. Pham; C. Xu, and J. L. Prince, Current methods in medical image segmentation. *Annu Rev Biomed Eng*, **2000**, 2, 315-37.
5. B. Khagi; C. G. Lee, and G.-R. Kwon, "Alzheimer's disease classification from brain mri based on transfer learning from cnn," in *2018 11th Biomedical Engineering International Conference (BMEiCON)*, 2018; pp. 1-4.
6. D. U. N. Qomariah; H. Tjandrasa, and C. Fatichah, "Classification of diabetic retinopathy and normal retinal images using cnn and svm," in *2019 12th International Conference on Information & Communication Technology and System (ICTS)*, 2019; pp. 152-157.
7. H. Lee; S. Eum, and H. Kwon, "Cross-domain cnn for hyperspectral image classification," in *IGARSS 2018-2018 IEEE International Geoscience and Remote Sensing Symposium*, 2018; pp. 3627-3630.
8. X. Lei; H. Pan, and X. Huang, A dilated cnn model for image classification. *IEEE Access*, **2019**, 7, 124087-124095.

9. L. Li; H. Huang, and X. Jin, "Ae-cnn classification of pulmonary tuberculosis based on ct images," in *2018 9th International Conference on Information Technology in Medicine and Education (ITME)*, 2018; pp. 39-42.
10. C. Dong; C. C. Loy; K. He, and X. Tang, "Learning a deep convolutional network for image super-resolution," in *European conference on computer vision*, 2014; pp. 184-199.
11. J. Yamanaka; S. Kuwashima, and T. Kurita, "Fast and accurate image super resolution by deep cnn with skip connection and network in network," in *International Conference on Neural Information Processing*, 2017; pp. 217-225.
12. Y. Zhang; Y. Tian; Y. Kong; B. Zhong, and Y. Fu, Residual dense network for image super-resolution. *Proceedings of the IEEE conference on computer vision and pattern recognition*, **2018**, 2472-2481.
13. Y. Chen; W. Li; C. Sakaridis; D. Dai, and L. Van Gool, "Domain adaptive faster r-cnn for object detection in the wild," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018; pp. 3339-3348.
14. J. Hung and A. Carpenter, "Applying faster r-cnn for object detection on malaria images," in *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, 2017; pp. 56-61.
15. S. Ren; K. He; R. Girshick, and J. Sun, "Faster r-cnn: Towards real-time object detection with region proposal networks," in *Advances in neural information processing systems*, 2015; pp. 91-99.
16. W. Chen; B. Liu; S. Peng; J. Sun, and X. Qiao, "S3d-unet: Separable 3d u-net for brain tumor segmentation," in *International MICCAI Brainlesion Workshop*, 2018; pp. 358-368.
17. L. Luo; D. Chen, and D. Xue, "Retinal blood vessels semantic segmentation method based on modified u-net," in *2018 Chinese Control And Decision Conference (CCDC)*, 2018; pp. 1892-1895.
18. A. Sevastopolsky, Optic disc and cup segmentation methods for glaucoma detection with modification of u-net convolutional neural network. *Pattern Recognition and Image Analysis*, **2017**, 27, 618-624.
19. Y. Guo; Y. Liu; T. Georgiou, and M. S. Lew, A review of semantic segmentation using deep neural networks. *International journal of multimedia information retrieval*, **2018**, 7, 87-93.
20. J. Zhang; J. Du; H. Liu; X. Hou; Y. Zhao, and M. Ding, Lu-net: An improved u-net for ventricular segmentation. *IEEE Access*, **2019**, 7, 92539-92546.
21. P. Xiuqin; Q. Zhang; H. Zhang, and S. Li, A fundus retinal vessels segmentation scheme based on the improved deep learning u-net model. *IEEE Access*, **2019**, 7, 122634-122643.
22. Z. Wei; H. Song; L. Chen; Q. Li, and G. Han, Attention-based denseunet network with adversarial training for skin lesion segmentation. *IEEE Access*, **2019**, 7, 136616-136629.
23. M. Goyal; A. Oakley; P. Bansal; D. Dancey, and M. H. Yap, Skin lesion segmentation in dermoscopic images with ensemble deep learning methods. *IEEE Access*, **2020**, 8, 4171-4181.
24. V. Badrinarayanan; A. Kendall, and R. Cipolla, Segnet: A deep convolutional encoder-decoder architecture for image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, **2017**, 39, 2481-2495.
25. Z. Zhou; M. Mahfuzur Rahman Siddiquee; N. Tajbakhsh, and J. Liang, Unet++: A nested u-net architecture for medical image segmentation. **2018**, arXiv:1807.10165.
26. C. Szegedy; W. Liu; Y. Jia; P. Sermanet; S. Reed; D. Anguelov, *et al.*, Going deeper with convolutions. **2014**, arXiv:1409.4842.
27. F. Chollet, Xception: Deep learning with depthwise separable convolutions. **2016**, arXiv:1610.02357.
28. M. Tan and Q. V. Le, Efficientnet: Rethinking model scaling for convolutional neural networks. **2019**, arXiv:1905.11946.
29. M. Sandler; A. Howard; M. Zhu; A. Zhmoginov, and L.-C. Chen, Mobilenetv2: Inverted residuals and linear bottlenecks. **2018**, arXiv:1801.04381.
30. N. Codella; V. Rotemberg; P. Tschandl; M. Emre Celebi; S. Dusza; D. Gutman, *et al.*, Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the international skin imaging collaboration (isic). **2019**, arXiv:1902.03368.
31. T. Mendonça; P. M. Ferreira; J. S. Marques; A. R. S. Marcal, and J. Rozeira, "Ph2 - a dermoscopic image database for research and benchmarking," in *2013 35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, 2013; pp. 5437-5440.